一种基于结构与词汇信息的本体概念名消歧法

王浩茂，梁铮，童凌，周志锋，罗凌云*

（南华大学 计算机科学与技术学院，湖南衡阳 421001）

摘要：解剖学基础模型（Foundational Model of Anatomy，简称 FMA）中部分概念的名称复杂，造成语义分析困难。其中一个普遍的难点在于，大量概念名称中存在多个“of”介词，使得其语法分析树并不唯一，从而引发歧义。提出一种自动消歧法来消除 FMA 概念名称中的歧义。根据本体中的图形层次结构，设计三个测试用例集，对含有单个“of”介词的概念名称进行分类。实验结果表明，该方法解析并消除了 FMA 中 90.95%的概念名称中原有的歧义。

关键词：消歧，图模型，本体

Dissecting the Ambiguity of FMA Concept Names Using Structural and Lexical Information

Tong Ling, Wang Haomao, Liang Zheng, Zhou Zhifeng, Luo Lingyun

(University of South China, School of Computer Science and Technology, Hunan, Hengyang, 421001)

Abstract: The complex inner structures of concept names in the Foundational Model of Anatomy (FMA) remain an obstacle for further analyzing the ontology using lexical methods. A very common problem is the ambiguity lying in names with the sometimes multiple occurrences of the preposition “of.” In this paper, we propose an automatic method to help disambiguating FMA terms by leveraging the taxonomy and partonomy information. We classified all the concept names with a single occurrence of the preposition “of” by the appearances of their sub-phrases in the parent names using three test suites. Results show that more than 90% of them can be provided with useful information to assist their correct parsing.

Keywords: Disambiguation , Graph model, Ontology

中图分类号：G203

1 引言

自然语言中普遍存在一词多义的现象。解剖学基础模型(Foundational Model of Anatomy)是医学信息学中一个常用的本体领域数据库，其中的概念名称均为抽象名词，难免存在歧义。而该本体中复杂的语义关系结构和缩略语的广泛使用[5]，给消除概念名称歧义的工作带来了一定困难。当前，已经存在部分方法用以解析生物医学本体概念名称[6-9]、消除歧义[10]，研究人员也在该领域取得了不错的进展[1-4]。其中一些方法通过术语中的词法信息，来解析概念名称中的语义结构[5,6,7] [11-13]。笔者在之前的工作中[13]，利用不相交的信息，提出一种使用图形表示的方法解析未确定的结构关系[14]。

然而，在 FMA 中存在一些单词数量众多（最多有 18 个单词）且结构复杂的概念名称，解析这种名称仍然具有难度。斯坦福大学的自然语言研究小组推出的语法分析工具(Stanford Parser)虽然在解析句子时成效显著，但解析那些带有“of”介词的 FMA 概念名称时，却只有少部分名称能够被准确地解析出来。因此，在分析解剖学名词短语结构的研究中，如何解决介词引起的歧义仍是一个难点。[10, 11] [16, 17]。

举一个简单的例子：Left surface of heart (心脏的左表面)，其中由于 left 的修饰范围不确定，所以 Left surface of heart 可以产生两种不同的解析树（图 1）。在下图左侧的解析树中，left 是用来修饰 surface of heart 的；而右侧的解析树中，left 仅仅是修饰 surface。

图 1 Left surface of heart 的两种分析树

当使用 Stanford Parser 处理工具分析 FMA 概念名称时，发现它分析得到的结果更偏向于上图中右侧的方式。在实际调查中，我们分析另一个名词 Mesothelial cell of parietal peritoneum (腹膜壁层间皮细胞) 和 Left surface of heart 时所得出的结果，都类似于图中右侧的解析树。虽然对于 Mesothelial cell of parietal peritoneum 来说，其解析结果是正确的，但是对于另一个样例 Left surface of heart 来说，这种分法得出的解析树却是错误的。在这个名称中，left 应该用来修饰 surface of heart ，而不是 surface。通常来说，像这种既有修饰词（通常第一个词就是修饰词）和又有介词 of 的概念名称中，修饰词的修饰范围不仅可以作用于 of 之前的词，也可以延伸至整个字符串的结尾。如果修饰词仅仅是修饰“ of”之前的单词，那么这个概念名称的解析树就会像图 1 中右侧一样。相反的，如果修饰词修饰到整个字符串的结尾，那么解析树就应该如同（图 1）左侧。因此不同的语义解析方法造成语义上的模糊，给语义分析造成了困难。为解决上述问题，本文提出一种基于本体结构信息的概念名消歧法，以减少 FMA 概念名称的歧义。

1 研究对象

FMA 作为一个常用的本体领域数据库，不仅和人体解剖学有关，也和人工神经理论[14]有关。我们的研究中使用的数据库来源是从开放生物医学本体（Open Biomedical Ontology ， OBO）实验室[18]所制作的 OWL[19]文件。

在 FMA 中，父节点和子节点的关系称为 subClassOf，其定义了父节点和子节点的上下级关系。Subclass 中含有 IS-A，Part-of 及其他各种不同的属性。根据该属性，概念名次被划分成了其特有的概念层次模型，就像其中的父节点关系：有用 subClassOf 表示的（例如 Right Hand subClassOf Hand），这种关系就是前面我们讲到的 IS-A 关系。与此同时，还有一种重要的关系是 Part-Of 关

系（例如 Hand part of Free upper limb）。通常，我们会使用分类学图谱来表示 IS-A 和 Part-Of 的关系。

本文的分析方法用到两种技术：一种是语义网技术（或称语义 Web），另一种就是斯坦福的自然分词工具（Stanford Parser）。在语义网技术中，我们用到 RDF[20]作为通用数据格式模型，它是以一种有向图模型的形式存在的。而 Web 本体语言（OWL[19]）是一种对指定的特定域有约束功能的形式语言。这就意味着，我们可以将名词的结构和意义保存在 RDF 模型中，并将 OWL 的本体抽象成 RDF/XML 数据流存储成图的形式。值得说明的是，SPARQL[21]将作为 RDF 的查询语言。

斯坦福自然分词工具（Stanford Parser）在接受了手动分析的训练后[15]，可以尝试着对新的词句进行更妥当的分析[22]。用 PCFG（Probabilistic Context Free Grammar）与一个学习语法语义和组合向量表达的递归神经网络 来进行语法解析[26]。虽然说它的解析能力在医学领域有一定局限性，但是其对生物学领域的名词识别还是很不错的[23]。并且这个解析器提供了斯坦福类型的语法依赖性和被识别短语的结构树，这些依赖结构已被用于从生物医学领域以帮助提取结构化医学知识并对我们的研究有一定帮助[24]。

2 分析与算法

我们提出一种基于本体结构信息的概念名消歧法，以减少 FMA 概念名称的歧义。同时，我们选用 FMA 中那些只存在一个介词 of，且 of 之前至少出现两个单词的概念名称作为我们的语料集。

表 1 名词分类及其数量

名词	所有概念名词	不含有 of 的名词	只出现一个 of 的名词	符合 A of B 格式且只有一个 of 的名词	研究对象名词
数量	78977	17100	35174	14153	21021

在整个 FMA 词库中，一共出现了 78,977 个概念名称。其中至少出现一个 of 的概念名称有 61,877 个。在这些拥有介词 of 的概念名称中，只出现一个介词 of 的有 35,174 个，其中 14,153 个概念名称的 of 之前只存在一个单词，并且这个单词肯定是名词。所以，我们的研究集中在剩下的 21,021 个概念名称上（相当于整个 FMA 词库的 27%）。这些概念名称仅有一个 of 出现，且 of 之前存在多个单词，我们可以确定的是，第一个单词往往都是修饰词。

对于上面提到的语料集中的每一个概念名称，我们采用三种测试方法，将其分别分解成不同的子短语，通过测试来帮我们确定每个概念名称中第一个修饰词的修饰范围。这个过程相当简单：对于概念名称 S，我们试探它的结果集合中的某个子短语是否在 S 的父节点中出现过。如果出现，该子短语很有可能在 S 的解析树中作为 S 的子树出现，其余的语料集中的概念名称都将会被这样测试，并最终得出结果。为了更好地理解本体中的层级关系，我们抽象出两种不同的父子关系：IS-A 父子关系和 Part-Of 父子关系。

例如，Left surface of heart 与 Region of surface of heart 是 IS-A 的关系，同时又是 Surface of heart 的一部分（Part-Of 的关系）。根据我们的测试方法，Surface of heart 将会

作为 Left surface of heart 的一棵子树，就像上文中图 1 左侧；对于 Mesothelial cell of parietal peritoneum 来说，在本体中它有一个父节点 Mesothelial cell，同时也和 Mesothelium of parietal peritoneum 组成 Part-Of 的关系。因此，根据我们的方法， 在 Mesothelial cell of parietal peritoneum 的解析树中，将会有两棵子树，分别为 Mesothelial cell 和 parietal peritoneum。通过减少歧义，我们的方法能更精确地解析 FMA 概念名称，并为那些基于本体质量评估的研究提供帮助。

为了确定修饰词 a0 在概念名称 S=(a0 a1 a2…an of S1) 中的修饰范围，我们设计了三种测试方法。每一种测试方法都会将一个概念名称分解出不同的子短语，并把这些子短语归纳成短语集合。第一种方法是用来检验 a0 的修饰范围是否修饰到 S 的结尾。第二种方法用来判断 a0 是否修饰介词 of 之前的名词。最后一种方法用来校验当前概念名称是否存在某个祖先节点能够通过前 2 种测试方法确定 a0 的修饰范围，接下来，我们给出上述三种测试方法的详细信息和解法。

2.1 方法一

该方法所产生的子短语集包含除了 a0 之外的所有后缀短语，其范围是[a1a2…an of s1] 到[an of s1]。举个简单的例子：概念名称 S 为 Posterior papillary muscle of left ventricle，它能分解出两个子短语：papillary muscle of left ventricle 和 muscle of left ventricle。如果子短语集中的某个子短语，在 S 的 IS-A 父节点中出现，同时也在 S 的一个或以上的 Part-of 父节点中出现，那么该子短语将会作为 S 解析树中的子树。

2.2 方法二

这种方法的子短语集将 S 为两个部分：[a0, a1…an]和[of s1]，对于概念名称 S，如果其父节点包含[a0, a1…an]但不包含[a0, a1…an of]（这表示[a0, a1…an]是独立于 of 存在的）或者是 S 的父节点包含 [of s1] 但不包含[an of S1] （这能够说明 of 是用以修饰 s1 的），那么子句[a0, a1…an] 将在解析树中被定义为 S 的子树。例如概念名称 S：Basivertebral foramen of thoracic vertebra 是 Basivertebral foramen 的子节点，同时也和 Body of thoracic vertebra 有 part of 关系，那么 Basivertebral foramen 将在 S 解析树中作为子树。

2.3 方法三

这种方法产生的子短语集只含有一个子短语[a0, a1…an of]（这个子短语称为 t）。如果 S 父节点包含 t，S 可能存在某个祖先节点的能够用上述两个方法来解析。例如：Spinous process of tenth thoracic vertebra 拥有一连串的 IS-A 关系：Spinous process of tenth thoracic vertebra→Spinous process of thoracic vertebra→ Spinous process of vertebra→Process of vertebra. 在第一种方法的帮助下，我们可以在 Spinous process of vertebra 这个节点使用第一种方法来确定 spinous 的修饰的是 process of vertebra，这样第 1 个修饰词的修饰范围也就确定了。

2.4 分类

在每个测试方法中，假设给定一个概念名称 S，通过测试方法将 S 分解出子短语集 T，根据 T 中的子短语与 S 父节点的关系分为四种不同的类别。类别 A：在集合 T 中存在一个子短语 s ∈ T，s 出现在 S 的 IS-A 父节点中，同时存在一个 s’ ∈ T，且 s’ 出现在 S 的 Part-Of 父节点中。 类别 B：存在一个 s ∈ T，s 出现在 S 的 IS-A 父节点中，但是 S 的所有 part of 父节点中不包含 s’（s’ ∈ T）。类别 C：S 的所有 IS-A 父节点中不包含 s’（s’ ∈ T）。但是存在至少一个 s ∈ T，s 出现在 S 的 part-of 父节点中。D：S 的所有 IS-A 父节点和 part-of 父节点中都不包含 s（s ∈ T）。示例插图（图 2）。

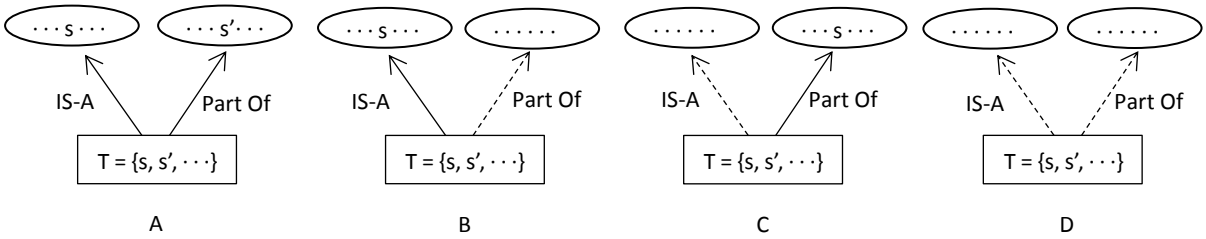

图 2 四种结果分类

需要特别注意的是，在第二种测试方法中，其测试标准比其他方法更加严格：倘若[a0, a1…an]出现在概念名称中，那么[a0, a1…an of]不能出现。相应的，当[of s1]出现时，[an of s1]就不应该出现。

对于每一个概念名称，我们根据测试方法的先后顺序进行测试：首先用第一种测试方法对语料库中的名称进行分类。如果第一种方法测试得到的分类是 D，这些分类为 D 的名称才会用第二种测试方法进行检测，而第二次检测得到的结果会是 DA，DB，DC，DD 这四种。那些被归类为 DD 的概念名称将会用第三种方法进行归类，其得到的结果会是 DDA，DDB，DDC，DDD。因此，在经过上述三种方法分类后，所有从 FMA 概念名称中将会被分为如下几个类别：A，B，C，D，DA，DB，DC，DD，DDA，DDB，DDC 和 DDD。只有被认为是 DDD（占总测试数据的 9%）的概念名称的子短语没有在父节点中出现。

例如概念名称 S 为 Spinous process of tenth thoracic vertebra，它有一个 IS-A 的父节点 Spinous process of thoracic vertebra 以及两个 Part-of 父节点 Tenth thoracic vertebra 和 Tenth thoracic vertebra arch。经过第一个测试方法后，子短语集中只有一个子短语：process of tenth thoracic vertebra。但它没有在 S 任意一个父节点中出现过。所以 S 被分类为 D，并进行第二种测试方法。第二个子短语集包含：Spinous process 和 of tenth thoracic vertebra，虽然 S 的 IS-A 父节点包含 Spinous process，但它同时含有 Spinous process of，所以它仍然是不符合要求的，会被分为 DD 级。在第三次测试中，子短语集中会有 Spinous process of，该子短语在 S 的 IS-A 父节点中出现过，但是子短语并没有出现在 S 的 Part-Of 父节点中，所以 S 最终将会被归类为 DDB。

2.5 算法

以下是用第一个方法测试概念名称 S=(a0a1...an of S1)（ai 代表一个单词而 S1 代表的是一个子短语）的算法，第二个和第三个测试的算法与之类似。

- 1、提取子短语集中的第一个子短语 S1，并初始化 mark_isa，mark_isa 为 false
- 2、在 Virtuoso RDF 库中使用一遍 SPARQL 查询，得到 S 的 IS-A 父节点，并判断 si 是否在父节点中出现，如果出现将 mark_isa 赋值为 true。
- 3、在 Virtuoso RDF 库中使用一遍 SPARQL 查询，得到 S 的 Part-Of 父节点，并判断 si 是否在父节点中出现，如果出现将 mar_partof 赋值为 true。
- 4、如果 mark_isa=true 且 mar_partof=true 同时成立，那么将 S 分为类别 A 并终止算法，否则进行第 5 步。
- 5、如果 si 已经是结果集中的最后一个元素了，那么根据 mark_isa 和 mark_partof 的取值给 S 分类，否则取结果集中的下一个元素进行 2-4 步的操作。

3 测试结果

结果显示了本文中提到的 10 个类别的具体数量和各自所占的百分比，比例基于语料库中的 FMA 概念的总数（21,021 个），详情请见（表 2）

表 2 分类结果

<table>
<tr><th colspan="8">各个分类的数量和百分比分布</th></tr>
<tr><td>A</td><td colspan="7">321 (1.52%)</td></tr>
<tr><td>B</td><td colspan="7">3025 (14.39%)</td></tr>
<tr><td>C</td><td colspan="7">1044 (4.97%)</td></tr>
<tr><td rowspan="5">D</td><td colspan="7">16631 (79.11%)</td></tr>
<tr><td>DA</td><td>DB</td><td>DC</td><td colspan="4">DD</td></tr>
<tr><td rowspan="3">396 (1.88%)</td><td rowspan="3">2217(10.55%)</td><td rowspan="3">1309 (6.22%)</td><td colspan="4">12709 (60.46%)</td></tr>
<tr><td>DDA</td><td>DDB</td><td>DDC</td><td>DDD</td></tr>
<tr><td>245 (1.17%)</td><td>10547(50.17%)</td><td>14 (0.07%)</td><td>1903 (9.05%)</td></tr>
</table>

事实表明，在语料集中一半以上的概念名称属于 DDB 这一类别，这可以说明那些被分为 DD 的概念名称（以下简称 S），虽然 S 的子短语不能在它的直接父节点上找到有用信息来确定第一个修饰词的修饰范围，但我们可以顺着 S 的父节点，向上多走几步，仍然有机在 S 的祖先节点上发

现一些不错的信息来帮助识别概念名称 S 的本意。总而言之，除了那 1903 个归类为 DDD（50%）的概念名称之外，其他名词都能通过上述方法找到有用的信息以帮助它们正确识别。

上述结果表明：实验产生的每个类别对确定修饰词的修饰范围所提供的帮助程度有所不同：虽然类别 A 能够起到决定性的作用，但是它的成立要求太苛刻。而那些和父节点没有“Part-of”关系的名称只能被归类到 B 或 D。我们利用类别 B 和 C 来帮助我们对概念名称进行分割。因为 IS-A 关系往往引出更抽象的概念，所以我们推测用 Part-Of 关系来识别名词可能是更可靠的，也就是说 C 可能会比类别 B 带给我们更多的有用信息。对于那 12709 个被分为 DD 的概念名称，前两种方法不能提供有效的信息来确定修饰词的修饰范围。这可能是我们的算法所限制的：在前两种算法中只使用直接相邻的节点。

4.结束语

当然，我们的工作存在许多局限性与不足。第一点是我们只考虑了包含一个“of”的概念名称。在以后的工作中，我们会把研究工作扩展到含有多个介词“of”的概念名称中。第二点是，一些概念名称可能需要从祖先节点而不是只有父节点获取有用的信息，在数据库中超过一半的概念名称属于 DDB 类可以说明这一点。（详见表 2）。我们认为，如果把搜索深度从父节点扩展到祖先节点，甚至是整套 FMA 概念名称。这样以后，那些具有确定性的类别中的数量将会增加，但是要求的计算复杂度也会提高。在[25]中，作者还使用了子串之间的关系来分析基因本体中的术语名称。与本文不同的是，他们的重点在于术语之间的关系，而不是每个术语名称的内部结构。

总的来说，我们的研究是对未知信息领域的一种初步尝试，它不仅可以提高词法分析方法工具的分析准确性，同时也为学者研究如何分析复杂概念名词做了必要的铺垫。

基金信息：

湖南省教育厅优秀青年项目：医学领域本体 SNOMED-CT 质量评估模型建立及应用研究，（14B153）

参考文献

[1] 黄昌宁，赵海. 中文分词十年回顾[M]. 北京：科学出版社, 1998, 第 21 卷(第 3 期): 8-19.

[2] 卢志茂，刘挺，李生. 统计词义消歧的研究进展[M]. 北京：电子学报, 2006,第 2 期: 333-343.

[3] 鹿文鹏，黄河燕，吴昊. 基于领域知识的图模型词义消歧方法[M]. 北京：自动化学报, 2014,第 40 卷(第 12 期): 2836-2850.

[4]徐哲，刘循. 贝叶斯决策树在英文现在分词词性识别中的应用[M]. 北京：计算机应用, 2009 ,第 29 卷(第 9 期): 2571-2574.

[5]于中华 ，陈蓉 ，胡俊锋等. 基于加权投票 K —近邻法的生物医学缩略语消歧[M]. 北京：中文信息学报, 2008, 第 22 卷(第二期): 18-23.

[6]Bodenreider O. Quality assurance in biomedical terminologiesand ontologies. Bethesda: Lister Hill National Center for Biomedical Communications, National Library of Medicine, 2010.

[7]Geller J, Perl Y, Halper M, et al. GuestEditorial: Special issue on auditing of terminologies. Journal of Biomedical Informatics, June, 2009, 42(3):407-411.

[8]Zhu X, Fan J W, Baorto D M, et al. A review of auditing methods applied to the content of controlled biomedical terminologies. J Biomed Inform, 2009, 42(3): 413-25. doi:10.1016 / j.jbi.2009.03.003

[9] Zhang G Q, Bodenreider O. Large-scale, exhaustive lattice-based structural auditing of SNOMED CT. AMIA Annu Symp Proc, 2010; 2010: 922926.

[10]杨晓恕，蒋维，郝文宁等. 基于本体和句法分析的领域分词的实现[M]. 北京: 计算机工程, 2008, 第 34 卷(第 21 期), 26-28.

[11] Bodenreider O, Burgun A, Rindflesch TC. Assessing the consistency of a biomedical terminology through lexical knowledge. International Journal of Medical Informatics, 2002, 67(1-3): 85-95.

[12] Zhang S, Bodenreider O. Aligning representations of anatomy using lexical and structural methods. AMIA Annu Symp Proc, 2003: 753-757.

[13] Rosse C, Mejino J L V. A reference ontology for bioinformatics: the foundational model of anatomy. Journal of Biomedical Informatics, 2003, 36: 478-500.

[14] Zhang G Q, Luo L, Ogbuji C, et al. An analysis of multi-type relational interactions in FMA using graph motifs. AMIA Annu Symp Proc, 2012.

[15] Klein D, Manning C D. Accurate unlexicalized parsing. Proceedings of the 41st Meeting of the Association for Computational Linguistics, 2003: 423-430.

[16] Vadas D, Curran J R. Adding noun phrase structure to the penn treebank. ACL, 2007.

[17] Vadas D, Curran J R. Parsing noun phrases in the penn treebank. Computational Linguistics, 2011, 37(4): 753-809.

[18]OBOFOUNDRY:http://www.obofoundry.org/

[19] Hitzler P, Krötzsch M, Parsia B, et al. OWL 2 Web Ontology Language Primer. W3C Recommendation, 2009.

[20]RDF:http://www.w3.org/RDF/

[21]SPARQL:http://www.w3.org/TR/rdf-sparql-query/

[22] Marneffe M C, Maccartney B, Manning C D. Generating typed dependency parses from phrase structure parses. LREC, 2006.

[23] Xu R, Supekar K, Morgan A, et al, Unsupervised method for automatic construction of a disease dictionary from a large free text collection. Annual American Medical Informatics Association Symposium, 2008: 820-824.

[24] Xu R, Das A, Garber A M. Unsupervised method for extracting machine understandable medical knowledge from a large free text collection. Annual American Medical Informatics Association Symposium, 2009: 709-713.

[25] Ogren PV, Cohen KB, Acquaah-Mensah G K, et al. The compositional structure of Gene Ontology terms. Pac Symp Biocomput, 2004: 214-25.

[26] Socher R, Bauer J, Manning C D, et al. Parsing with Compositional Vector Grammars[C]// Meeting of the Association for Computational Linguistics. 2013:455-465.