学校 南华大学　　参赛类别 自然科学类

第七届南华大学“挑战杯”课外学术科技作品竞赛

作品申报论文

面向知乎的个性化推荐系统研究

Research on Personalized Recommendation System Based on Zhihu

参赛队员 1：童凌

参赛队员 2：刘澜

参赛队员 3：王成

参赛队员 4：魏胜

指导老师：李晓昀（副教授）

指导老师：欧阳纯萍（副教授）

2016 年 11 月

面向知乎的个性化推荐系统研究

童凌 刘澜 王成 魏胜

（南华大学计算机科学与技术学院 衡阳 421001）

摘 要：信息泛滥的互联网之中，真正有价值的信息对于个人而言是绝对的稀缺品。知乎连接着各行各业的精英，持续产生着高质量、可沉淀的信息，但有价值的信息和用户之间并未紧密关联。

知乎作为面向互联网的智能问答平台，其推荐信息具有随机性。为提高用户与信息间的关联度，本文提出一个基于混合算法的个性化推荐模型，以教育部公布的 13 个学科类和知乎用户为具体研究对象，构建学科标签数据集、用户数据集、个性化推荐算法模块。系统模型根据问答信息提出 Pr-rank（ Problem Rank）函数，同时对学科类问答信息标签化处理形成学科标签数据集。系统模型根据知乎用户信息提出用户 Pe-rank（Person Rank）函数,结合其兴趣学科标签形成用户数据集。个性化推荐算法模块主要采用内容推荐与用户协同过滤推荐算法输出 top-k 的推荐信息。实验结果表明，系统对用户兴趣判断较准确且推荐效果良好。

关键词：个性化，用户模型，内容推荐，协同推荐

Research on Personalized Recommendation System Based on Zhihu

Wang Zhenhai，Liu lan ，Wang Cheng，Wei Sheng

（School of Computer Science and Technology, University of South China, Hengyang, Hunan, China, 421001 ）

Abstract: The Internet contains a wide range of large-scale data, and valuable content of them remains a scarcity for individuals. Zhihu, the most popular online Q&A community in China, is continuously producing thousands of quality questions and answers to connect elites from all walks of life. However, the structural relationship between users and valuable contents are incomplete. As for the most widely used Q&A platform, the personalized services, such as valuable information recommendation, are too random to be considered as a flaw. In order to improve the correlation value between users and contents, we construct a subject-based dataset, a user-based dataset and revise algorithms by leveraging the information about users and the classifications of 13 subjects in the Ministry of Education. According to the contents of questions and answers, We propose a function called "Problem Rank" to classify and label them into a separated subject-based dataset. We further adopt "Person Rank" function on the basis of user's information, combining them with the subject-based dataset. Finally, we build up a user-based dataset. Then, the algorithmic module outputs top k questions and answers by means of contents-recommending system and the collaborative filtering recommendation algorithm. Results demonstrated the algorithm recommends considerably more accurate contents to meet the users' interests.

Key words:Personalized recommendation , System modeling ，Content recommendation，Collaborative recommendation

1 引言

知乎连接着各行各业的精英，用户分享彼此的专业知识、经验和见解，持续产生着高质量、可沉淀的信息，但有价值的信息和用户之间并未紧密关联。系统化、组织化的高质量信息还存在于不同个体大脑之中，尚未得到有效的挖掘、利用和分享。而优秀的推荐系统能够有效根据用户的信息需求、兴趣等，进行个性化推荐推荐信息，达到有效挖掘、高效利用和分享资源的目的。

但就目前而言知乎推荐信息具有随机性，未根据用户兴趣特点推荐其所感兴趣的话题，导致用户无法得到高质量信息而重复问答相似话题，造成回答信息质量下降、相似问题泛滥、服务稳定性降低等问题。本文提出面向知乎的个性化推荐系统，从用户数据集、学科标签数据集、个性化推荐算法模块架构构建推荐平台。采用基于内容推荐与基于用户协同过滤推荐算法，达到有效推荐用户需求信息，让用户与有价值信息紧密联系起来的目的。

2 个性化推荐系统综述

2.1 个性化推荐算法

推荐算法是整个推荐系统中最核心的部分，在很大程度上决定推荐系统类型和性能的优劣。目前主要的推荐算法包括：基于内容的推荐、协同过滤推荐及其他推荐。

2.2 基于内容的个性化推荐算法

基于内容的推荐（content-based recommendation）根据用户已经关注的对象，从推荐对象中选择与其他对象相似的特征作为推荐结果。这一推荐策略提取推荐对象的内容特征，和用户模型中其他用户的兴趣偏好匹配，将匹配度较高的推荐对象作为结果推荐给用户。例如在进行电影推荐时首先将电影信息分类并计算用户在分类标签下的权值，然后从对应兴趣标签集中选取匹配度高的作为输出结果。该推荐算法的优点是简单有效、推荐结果直观、无稀疏性问题、冷启动问题、具有比较成熟的分类方法为该算法提供支持，缺点是很难出现新领域下的推荐结果、对推荐对象内容分类方法需要的数据量较大。因此基于内容的推荐算法适用于内容具备分类标签，用户具备分类标签权值的平台。

2.3 基于协同过滤的个性化推荐算法

协同过滤推荐（collaborative filtering recommendation）是推荐策略中最成功的算法。协同过滤的基本思想借鉴了日常选购商品、选择书籍时的方法。若自己身边的很多朋友都选购某件商品，那么自己就会有很大的概率选择该商品。协同过滤推荐的用户模型为用户—项目评价矩阵。例如在进行微博信息推荐时处理掉噪音数据，筛选出用户兴趣偏好信息，然后根据评价矩阵选择与用户 U_0 相似的用户 U_i 产生推荐信息。基于协同过滤的推荐算法优点是随着用户量的增加推荐性能不断提升、可推荐复杂的非结构化对象、善于

发现用户的新兴趣点，缺点是存在稀疏性问题、冷启动问题、系统初始推荐质量差及推荐质量取决于历史数据集。因此基于协同过滤的推荐算法适用于用户之间关系紧密、用户数据集丰富的平台。

3 基于混合算法的个性化推荐模型构建

3.1 数据预处理

3.1.1 数据收集

分析知乎主页，利用 GS 浏览器定义规则获取知乎数据，处理噪音数据、撅弃偏差值和无关信息，从 5000 条信息中筛选出 100 条与学科类相关的数据。筛选得到历史、英语、数学、物理学、经济学、化学、生物学、电工、电气工程、马克思经济学 10 大专业的数据，并各选出与此 10 个专业相关的 10 个用户和 10 个话题，保留以上信息对其进行分类处理。

如表 3.1 所示，对每个用户保留其性别、赞同量、回答问题量、被关注量、关注的相关专业和在专业下回答的次数等信息。如表 3.2 所示，对每个问答保留其问题标题、问题内容、问题回答量、问题被赞量和此回答用户的权值等信息。

用户编号	性别	赞同量	回答量	被关注量	主页被浏览量	专业	回答	专业	回答	话题	回答
1	0	13887	69	2452	13818	历史	9	1	经济学	1	1
2	0	45012	186	11835	49161	电工	11	9	历史	7	9
3	0	65146	98	3028	15698	电工	16	2	生物学	1	10

表 3.1 电气工程专业用户信息

问题ID	问题标题	问题内容	问题回答量	被赞量	回答用户权值	被赞量	回答用户权值	被赞量	回答用户权值
1	T1	P1	106	222	4	135	1	24	3
2	T2	P2	13	1338	5	1	1	21	3
3	T3	P3	111	3093	5	471	4	37	2

表 3.2 电气工程专业问答信息

3.1.2 数据分析

全局数据分析：全局数据信息能够体现整体用户的兴趣偏向，对新注册用户可推荐整体用户所关注的话题，有效提升新注册用户的活跃度。

用户偏好统计：如表 3.3 所示体现用户在关注某一话题之下可能会关注其他话题的概率，其后可作为基于内容推荐与基于用户协同过滤推荐的依据。

专业	历史	英语	数学	物理	经济学	化学	生物学	电工	电气工程	马克思经济学
历史	\	3/17	3/17	1/17	7/17	1/17	0	2/17	0	0
英语	4/18	\	3/18	0	5/18	4/18	2/18	0	0	0
数学	0	0	\	9/12	1/12	0	1/12	0	0	1/12

表 3.3 用户兴趣偏好统计图

3.2 个性化推荐模型构建

知乎平台内容具备标签分类、用户之间关联度高、用户与信息关联度高的特点。结合 2.2 与 2.3 所描述的个性化推荐算法，本文提出一种基于混合算法的、个性化模型，构建用户数据集、学科标签数据集、个性化推荐算法模块。采用基于内容推荐与基于用户协同过滤推荐的混合推荐算法输出 top-k 的推荐信息。

对用户数据进行分析，引入 Pe-rank 函数，表示用户 U_0 在知乎用户数据集中的权重排名，保留用户个人基本信息如用户 ID、性别、被关注量、关注量、回答量、关注学科、用户排名等信息。根据问答信息引入 Pr-rank 函数，表示问题 P_0 在标签数据集 S_i 下的权重，保留问题内容、回答内容、回答人数、回答用户被赞量、回答用户权值、问题排名等信息。采用基于内容推荐算法、基于用户的协同过滤推荐算法、Pe-rank 函数、Pr-rank 函数、贝叶斯函数、修正余弦函数、滑动窗口等实现个性化推荐系统核心。

通过 Pe-rank 函数、Pr-rank 函数计算整体用户兴趣偏好并为新用户输出全局 top-k1 推荐信息。通过基于内容推荐算法，选择用户已关注的学科标签，利用贝叶斯函数计算用户可能关注的学科标签，将标签传至学科数据标签集中，产生 top-k2 推荐信息。通过修正余弦函数选择与用户 U_0 相似的用户 U_i，产生 top-k3 的推荐信息。根据热点话题，产生 top-k4 的推荐信息。最终基于滑动窗口算法维持输出全局 top-k 推荐信息。

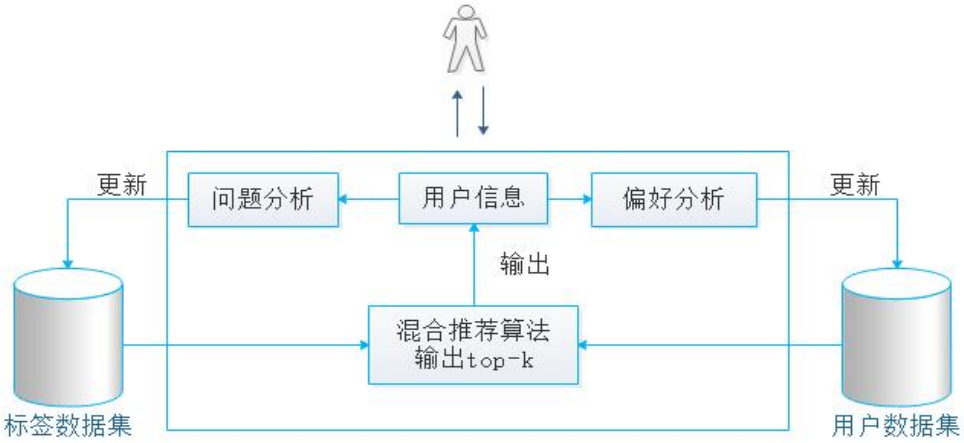

图 3.1 个性化推荐系统结构

3.3 构建用户模型

3.3.1 用户数据集内容

针对用户建立个人用户数据集，在包含姓名、性别、学历、职业、年龄、兴趣偏好等个人基本信息之外，另增加用户在其关注学科标签内权重和用户在知乎平台下排名。

3.3.2 用户学科权重值

如表 3.4 所示，根据用户在关注学科下回答问题数量和回答被赞量、用户擅长学科等信息引入权重 Tk-value，表示在第 k 个关注学科中权重为 value，用户在其关注学科标签下权重共分 5 个等级，由 1-->5 逐渐增高。

专业	历史	英语	数学	物理	经济学	化学	生物学	电工	电气工程	马克思经济学
User1	0	0	1	5	0	1	0	0	0	0
User2	1	0	0	2	0	1	0	3	0	0
User3	3	0	1	1	3	0	0	0	0	0

表 3.4　用户学科权重值

3.3.3 计算 Pr-rank 函数

根据用户主页被浏览量、关注人数、被关注人数、所属院校、个人成就、问题回答质量等信息引入 Pr-rank 函数表示用户价值。

主成分分析：如表 3.5 和表 3.6 所示，通过对各个因子中的成分进行分析，隔离判断主因素对因变量的影响程度，结果显示，性别、主页被浏览量、被关注人数、被赞量、问答量占据总影响因素的 80%以上。

组件	初始特征值			提取载荷平方和		
	总计	方差百分比	累积 %	总计	方差百分比	累积 %
1	1.010	50.503	50.503	1.010	50.503	50.503
2	.990	49.497	100.000			

表3.5 总方差解释　提取方法：主成份分析

组件		初始特征值			提取载荷平方和		
		总计	方差百分比	累积 %	总计	方差百分比	累积 %
原始	1	8.354	97.778	97.778	8.354	97.778	97.778
	2	.190	2.222	100.000			
重标	1	8.354	97.778	97.778	1.000	50.005	50.005
	2	.190	2.222	100.000			

表 3.6 总方差解释　提取方法：主成份分析

经主成分分析得出，主要影响因素为性别、赞同量、回答量、被关注量、主页浏览量。

采用K-均值聚类检验，验证分析所得到的主要因素是否正确。

因素	聚类	
	1	2
赞同量	191	309841
被关注量	22	89328
主页浏览量	421	734017
回答量	44	3050

表3.7 初始聚类中心

因素	聚类	
	1	2
赞同量	21062	268188
被关注量	8395	97227
主页浏览量	29557	591354
回答量	153	3025

表3.8 最终聚类中心

	平方和	自由度	均方	F	显著性
回归(R)	9148373892.004	1	9148373892.004	2.759	.101
残差	258642709856.183	78	3315932177.643		
总计	267791083748.187	79			

表3.9 ANOVA 自变量为性别

如3.7、3.8、3.9所示，性别的影响程度的显著性远大于0.05，因此不适合成为主要影响因素。

	平方和	自由度	均方	F	显著性
回归(R)	29.352	3	9.784	1.179	.323
残差	630.648	76	8.298		
总计	660.000	79			

表3.10 ANOVA 自变量为赞同量

下面分析赞同量、问答量、被关注量、主页浏览量四个因素对Pe-rank函数的影响。

	非标准化系数		标准系数	t	显著性
	B	标准错误	贝塔		
赞同量	5.260E-5	.000	1.060	1.441	.154
赞同量 ** 2	-5.383E-10	.000	-2.706	.	.
赞同量 ** 3	1.154E-15	.000	1.600	.	.
（常量）	5.227	.439		11.901	.000

表3.11 赞同量系数

由表3.10、表3.11得出，赞同量与因变量间的关系为$\ln x$的形式，通过观察拟合图3.2符合要求。

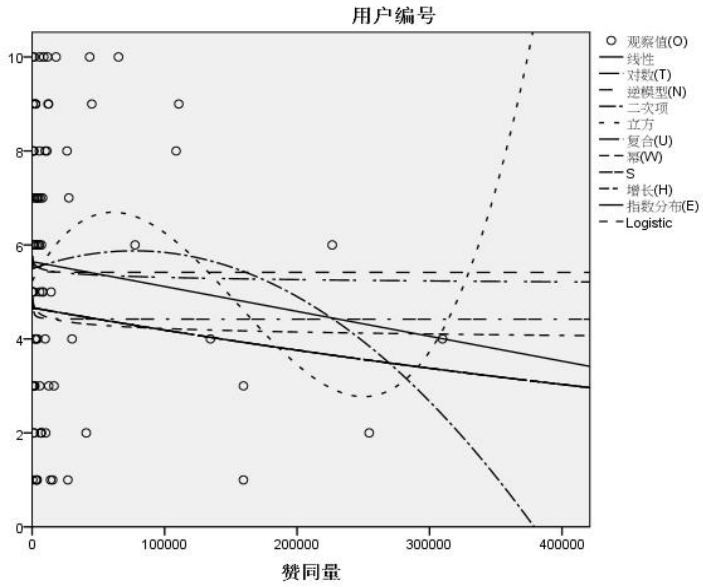

图3.2　赞同量与因变量关系

经同样分析方法分析出回答量、被关注量、主页浏览量与Pe-rank之间的关系。因为各主成分的显著性水平均低于0.05，因此在目前可得情况下，分析结果是相对准确的，可得到如下函数表达式（注:x1被赞量，x2回答量，x3被关注量,x4主页浏览量）

$$Pe_rank = a*\ln x_1 + b*x_2^3 + c*x_3^2 + d*\ln\frac{1}{x_4} + e$$

用户数据集：综上分析得到用户数据信息如表3.12所示。

UserID	Name	Year	Major	Label	L1-value	Labelk	Lk-value	Pe-rank
User1								
User2								
User3								

表3.12

3.4构建学科标签数据集模型

3.4.1构建学科标签

构建学科标签：根据我国高等教育专业设置按“学科门类”设置一级学科大类列表，分为哲学，经济学，法学，教育学，文学，历史学，理学，工学，医学，军事学，管理学，艺术学13大类。

根据一级学科标签构建二级专业标签：针对13大门类，每大门类下设若干二级学科，如哲学门类下设宗教学，中国哲学，外国哲学，逻辑学，伦理学，美学，科学技术哲学，马克思主义哲学8大专业。

形成标签数据集：经3.3.3同样方法分析出影响问题排名的主要因素，最终得到主要影响因素为问答中问题内容、问题评论数量、问题回答用户被赞量与回答用户权值、时间，通过上述影响因素引入Pr-rank函数表示问题价值。

3.4.2问答数据分析

因选取问答均为各学科类文章，所以不需用TF-IDF等自然语义处理算法对文章主题分析，直接计算Pr-rank函数。

	非标准化系数		标准系数	t	显著性
	B	标准错误	贝塔		
问题评论量	1.001	.001	1.099	1287.093	.000
（常量）	.209	.027		7.691	.000

表 3.13 赞同量系数

由表 3.13 得出，问题评论量与因变量间的关系为线性关系，通过观察拟合图 3.3 符合要求。

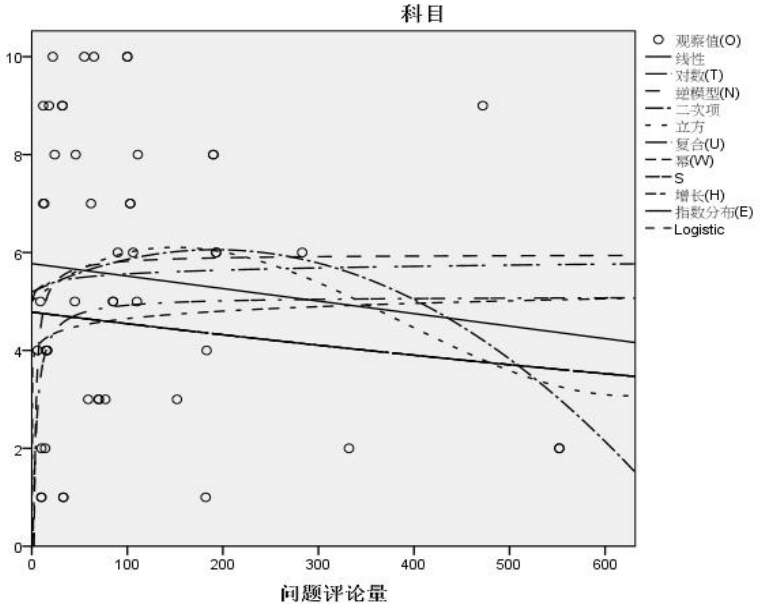

图 3.3 问题评论量与因变量关系

经同样分析方法分析出问题回答量、用户被赞量、回答用户权值、时间与因变量之间关系，可得到如下函数表达关系式。(注：x1为问题评论量，x2被赞量，x3回答用户权值,t为时间）

$$\Pr_rank = a * x_1 + b * \ln x_2 + c * e^{x_3} + d * \frac{1}{\ln t} + e$$

问题数据集：综上分析得到问题问答数据信息为表 3.14 所示

ProblenID	问题描述	所处学科	回答用户被赞量	回答用户权值	问题排名
Pro1					
Pro2					
Pro3					

表 3.14

4 混合推荐算法及 top-k 输出

4.1 基于内容的推荐算法

基于内容的推荐算法首先提取用户所关注的学科标签信息，将学科标签传至学科数据标签集。从学科标签数据集中选择 top-k1 的问答话题，根据贝叶斯分类器选择在其所关注的学科集中可能关注其他学科 top-k2 的问答问题。

从用户个人数据集中选取所关注的学科专业 S_i 传至学科标签数据集中，判断其所属第一标签“学科”与第二标签“专业”，在专业领域内通过 Pr-rank 函数找出 top-k1 的推荐信息放入待推荐信息数据集之中。图 4.1 为寻求数学专业内问答信息流程。

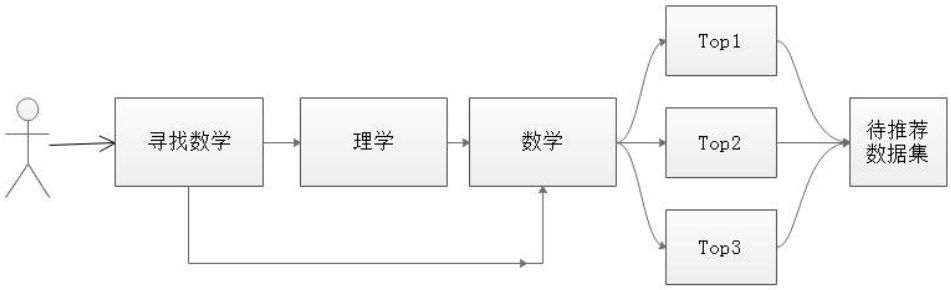

图 4.1 基于内容推荐

分析出总体用户的偏好特征后，利用贝叶斯分类器寻求其可能关注的学科，当已关注学科专业集合 $S\{S_{k1}、S_{k2}、S_{kn}\}$ 的情况下求出其最可能会关注学科专业 S_i 的概率，选出概率最高的 S_i，通过图 4.2 同样方法求得 top-k2 的推荐信息，将其放进待推荐信息数据集中。

$$P(S_i \mid S) = \frac{P(S_i)P(S \mid S_i)}{\sum_{j=1}^{n} P(S_j)P(S \mid S_j)} (i = 1,2...n)$$

4.2 基于用户的协同过滤推荐算法

基于用户的协同推荐是寻找与用户 U_0 相似的用户 U_i，推荐 U_i 关注而用户 U_0 未关注的学科专业。基于用户的协同过滤推荐算法主要是查询最相似的用户和产生推荐信息，其核心为查询最相似用户，构建用户—学科权重矩阵的方法求最相似用户，其过程如图 4.2 所示。

图 4.2 基于用户的协同过滤推荐流程

构建评分矩阵：本文所研究的为知乎学科领域，所以采用内容-学科矩阵，如表 4.1 所示表示用户 i 对第 j 个学科的权重值，每个用户对推荐对象的权重可看做是一个 m 维向量，度量用户间相似度就可以用 m 维向量间的相似度来衡量，此处权重值已在上文中求出。

	学科 1	……	学科 k	……	学科 n
用户 1	$V_{(1,1)}$		$V_{(1,k)}$		$V_{(1,n)}$
…… ……	……	……	……	……	……
用户 m	$V_{(m,1)}$		$V_{(m,k)}$	……	$V_{(m,n)}$

表 4.1 用户-学科权重

用户相似度计算：余弦相似性未考虑用户权重尺度问题，如对用户 U_1 来说权重值在 2 上才会关注而对用户 U_2 来说权重值在 3 以上才会关注，所以本文采用修正余弦函数相似性计算用户相似度。

修正余弦函数相似性通过减去用户对推荐对象平均评分的方法来改善上述缺陷。设用户 i 和用户 j 共同关注过的推荐对象集合用 $S_{i,j}$ 表示，S_i 和 S_j 分别表示用户 i 和用户 j 已关注过的学科标签集合，则用户 i 和用户 j 之间的相似性用 sim(i,j)如下所示，其中 $P_{i,k}$ 表示用户 i 对学科标签 k 的权值，$\overline{P_i}$，$\overline{P_j}$ 分别表示用户 i 和用户 j 的平均评分。

$$Sim(i,j)=\frac{\sum_{k\in S_{i,j}}(P_{i,k}-\overline{P_i})(P_{j,k}-\overline{P_j})}{\sqrt{\sum_{k\in S_i}(P_{i,k}-\overline{P_i})}\sqrt{\sum_{k\in S_j}(P_{j,k}-\overline{P_j})}}$$

设用集合 $P-S_n$ 表示与目标用户 u 相似的所有用户，那么对用户 u 的推荐信息可以通过用户集合 $P-S_n$ 中用户 U_i 对其他学科标签信息评分得到。其中 sim(u,n)表示用户 u 与用户 n 之间的相似性，设 $P_{n,j}$ 表示用户 n 对推荐对象 i 的权重，$\overline{P_u}$ 和 $\overline{P_n}$ 分别表示用户 u 和用户 n 对推荐对象的平均评分。

$$R_{u,i}=\overline{P_n}+\frac{\sum_{n\in P-S_n}sim(u,n)*(P_{n,i}-\overline{P_n})}{\sum_{n\in P-S_n}|sim(u,n)|}$$

经上述方法求得用户 u 最相似的用户集及待推荐的学科标签，将待推荐学科标签通过基于内容推荐所示的方法求得 top-k3 的推荐信息，将其放进待推荐信息数据集之中。基于用户的协同推荐如图 4.3 所示。

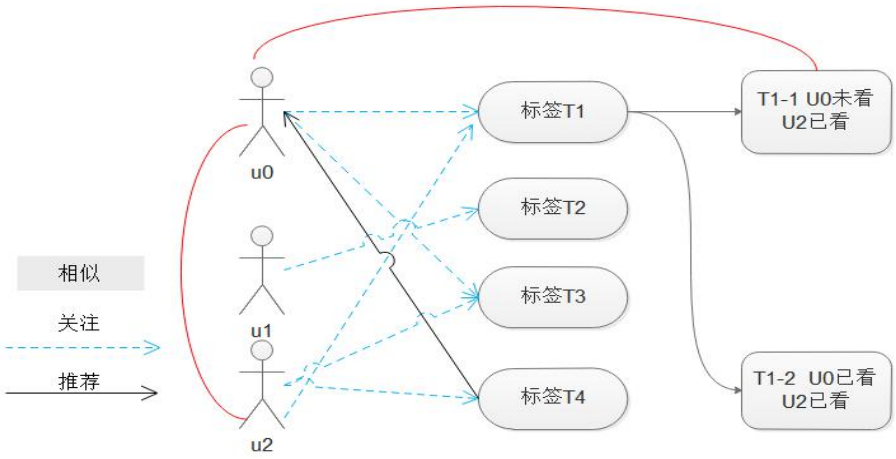

图 4.3 基于用户的协同过滤推荐

4.3 其他信息推荐

4.3.1 热点信息推荐

用户同样会浏览最新动态的热点话题，关注学科内最新话题。根据高明[12]提出维持新近最热门 k 条信息的方法、Mouratidis 等人提出的流数据上基于滑动窗口模型查询 top-k 信息算法求得问答排名中 top-k4 的问答信息放入待推荐信息数据集之中。

4.3.2 冷门信息推荐

为平衡信息关注度，挖掘冷门回答信息，提高整体用户活跃度，有效平衡信息长尾效应。本文根据 Pr-rank 函数选出排名较低的 top-k5 的问答信息放入待推荐信息数据集中。

4.4 全局 top-k 列表推荐信息输出

根据上文求得的 top-k1 至 top-k5 信息再次筛选，最终得到 top-k 列表的推荐信息。因信息被赞量、被转发量、时间等因素，其排名不断变化，而我们需要实时获取全局 top-k 推荐信息，因此通

过 Pr-rank 函数与滑动窗口算法维持 top-k 的结果。因各推荐信息具有本质差异性，如 4.1 基于内容进行推荐、4.2 基于用户协同进行推荐，所以应先分类待推荐信息然后通过滑动窗口进行推荐。

top-k1 与 top-k2 基于同种属性选用滑动窗口 W1、top-k3 为用户协同信息选用窗口 W2，top-k4 信息为动态热门信息具有实效性，采用流数据窗口模型，top-k5 信息选用滑动窗口 W3。滑动窗口内判定规则依据用户排名与问题排名两种规则，W1、W2、W3 窗口模型相同，如图 4.4 所示。

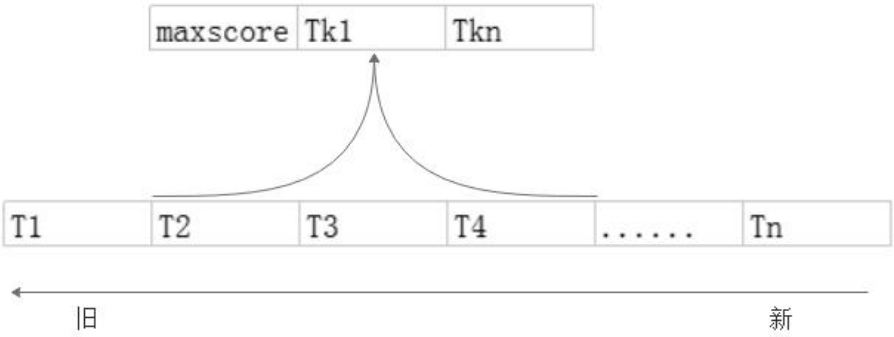

图 4.4 滑动窗口模型

最终选择 Top-k 信息进行输出推荐给用户。

top-k= α *top-k1+ β *top-k2+ γ *top-k3+ δ *top-k4+ ε *top-k5。

5 实验结果分析

5.1 实验设计

获取知乎学科标签类数据于用于数据，通过数据预处理减少数据波动性与随机性，得到用户关注学科标签集、标签数据集关联度

矩阵、用户关联相似度，对行列式信息进行归一化处理，通过程序模拟推荐过程，结合 Pe-rank 函数与 Pr-rank 函数输出推荐结果。

5.2 实验步骤

为减小数据波动性与随机性，先对获取数据进行预处理。通过切比雪夫大数定律，设置阈值为 50，去掉奇异值，如图 5.1 所示，在 40-60 范围内的四个奇异点是不符合大多数规律的，因此本文将对剩下的数据进行拟合处理，根据用户数据集进行分析。

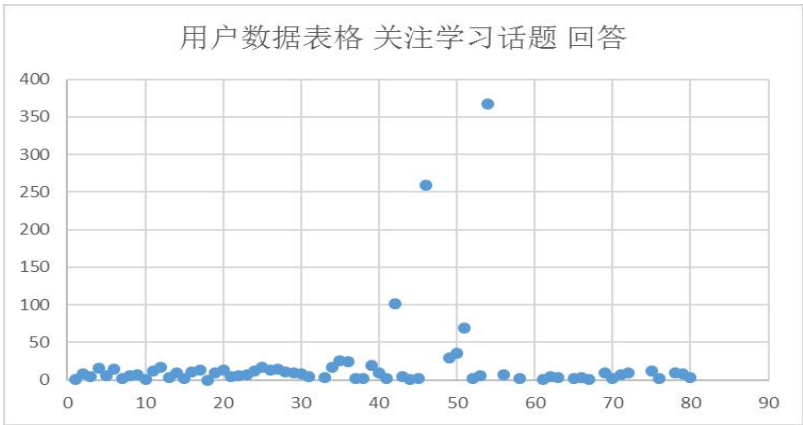

图 5.1 用户数据表格

设数据集 S={历史，英语，数学，物理，经济学，化学，生物学，电工，电气工程，马克思经济学}。通过 GS 浏览器定义规则获取每类 1000 组数据，共 10 类，通过随机性误差处理去掉奇异值，再对所留数据进行统计，汇总，得到如表 5.1 所示的在该数据集内关联度矩阵（注：为保证系统稳定性，统一预先设定矩阵对角元素关联度为 0）。

$$\begin{bmatrix} 0 & 3/17 & 3/17 & 1/17 & 7/17 & 1/17 & 0 & 2/17 & 0 & 0 \\ 4/18 & 0 & 3/18 & 0 & 5/18 & 4/18 & 2/18 & 0 & 0 & 0 \\ 1/19 & 1/19 & 2/19 & 7/19 & 3/19 & 2/19 & 1/19 & 0 & 2/19 & 0 \\ 0 & 0 & 0 & 9/12 & 1/12 & 0 & 1/12 & 0 & 0 & 1/12 \\ 2/14 & 1/14 & 0 & 0 & 11/14 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1/14 & 1/14 & 2/14 & 0 & 9/14 & 1/14 & 0 & 0 & 0 \\ 6/20 & 3/20 & 0 & 2/20 & 3/20 & 6/20 & 0 & 0 & 0 & 0 \\ 2/20 & 1/20 & 2/10 & 5/20 & 4/20 & 2/20 & 2/20 & 0 & 2/20 & 0 \\ 4/18 & 2/18 & 0 & 3/18 & 5/18 & 0 & 0 & 4/18 & 0 & 0 \\ 4/13 & 1/13 & 0 & 1/13 & 7/13 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

表 5.1　数据集内关联度矩阵

处理矩阵获取行列式并对数据进行归一化处理。通过对每一学科类数据进行直方图分析，如表 5.2、表 5.3 为化学与生物学学科专业的图表，其余学科类专业以相同方式进行处理。

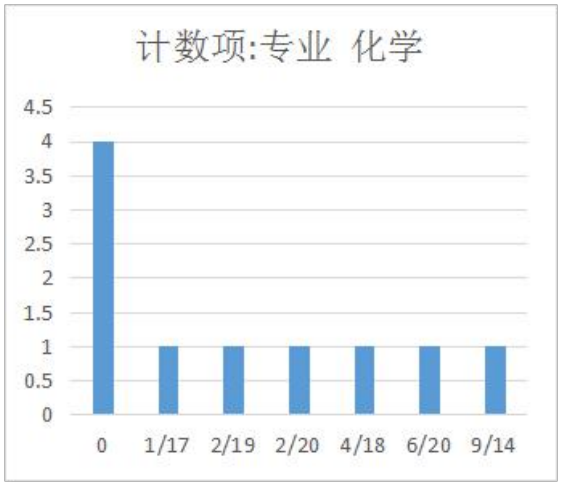

图 5.2

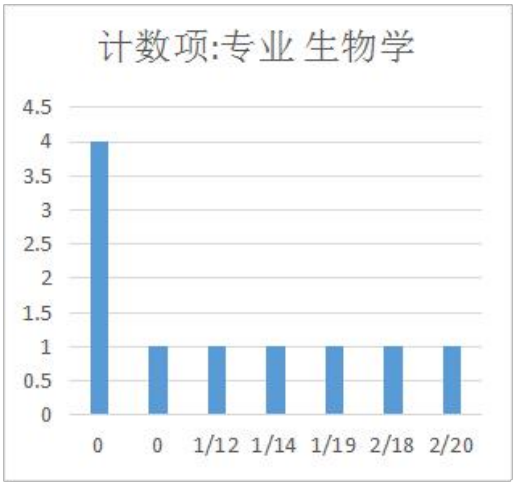

图 5.3

获取数据集中各科目相关度面积图累加，减小数据误差进行检验。

专业	历史	英语	数学	物理	经济学	化学	生物学	电工	电气工程	马克思经济学
马克思经济学	0	0	0	1/12	0	0	0	0	0	0
电气工程	0	0	2/19	0	0	0	0	2/20	0	0
电工	2/17	0	0	0	0	0	0	0	4/18	0
生物学	0	2/18	1/19	1/12	0	1/14	0	2/20	0	0
化学	1/17	4/18	2/19	0	0	9/14	6/20	2/20	0	0
经济学	7/17	5/18	3/19	1/12	11/14	0	3/20	4/20	5/18	7/13
物理	1/17	0	7/19	9/12	0	2/14	2/20	5/20	3/18	1/13
数学	3/17	3/18	2/19	0	0	1/14	0	2/10	0	0
英语	3/17	0	1/19	0	1/14	1/14	3/20	1/20	2/18	1/13
历史	0	0.22	1/19	0	2/14	0	6/20	2/20	4/18	4/13

图 5.4

5.3 实验结果

通过实验，在数据集 S 中，所得结果是{0.256, 0.213, 0.115, 0.113, 0.073, 0.045, 0.051, 0.021, 0.034, 0.029}。社科类文献比例最高，其次为学科方面，然后逐一递减。个性化推荐系统所得数据是符合个性化真实情况的，与现有的知乎推荐系统相比能够有效根据用户兴趣偏好推荐个性化信息，具有实际意义。

6 结束语

在信息冗余的时代，用户应和有价值的信息产生更紧密的联系，为此我们改进了知乎传统的信息推荐算法，构建最新的个性化推荐系统，对传统的知乎推荐方式改革创新。所以在构

建面向知乎的推荐系统时，我们注重用户个性、用户与知识间的紧密联系，强调发挥用户的主体作用，把基于内容推荐、基于用户协同过滤推荐引入推荐系统中，达到提高用户之间联系、提高信息利用率、用户与有价值信息紧密结合的目的。

本文提出的面向知乎的个性化推荐系统对随机选取的学科标签进行实验，并对比知乎现有的推荐系统，结果显示能够有效根据用户兴趣偏好和用户相似性推荐个性化信息，推荐质量得到明显提高，信息利用率得到较大改善。把个性化与问答平台结合起来是推荐系统的新思路，仍处于探索阶段，类似于本文中所面临的兴趣标签交叉、冷启动问题仍待解决，未来面向知乎的个性化推荐系统与机器学习、复杂网络理论、多维推荐、数据挖掘等技术相结合必将得到更大的推广应用。

参考文献

[1]王国霞,刘贺平. 个性化推荐系统综述[J]. 计算机工程与应用,2012,07:66-76.

[2]刘建国,周涛,汪秉宏. 个性化推荐系统的研究进展[J]. 自然科学进展,2009,01:1-15.

[3]李晓昀,阳小华,余颖. 基于隐性反馈分析的个性化推荐研究[J]. 计算机工程与设计,2009,16:3794-3796+3825.

[4]刘建国,周涛,郭强,汪秉宏. 个性化推荐系统评价方法综述[J]. 复杂系统与复杂性科学,2009,03:1-10.

[5]单明. 基于个性化推荐的电子商务推荐系统的设计与实现[D].吉林大学,2014.

[6]花青松. 个性化推荐系统用户兴趣建模研究与实现[D].北京邮电大学,2013.

[7]李晓昀,余颖. 基于隐性反馈的自适应推荐系统研究[J]. 计算机工程,2010,16:270-272+275.

[8]孙娟,王熙照. 自适应模糊决策树算法[J]. 计算机工程与设计,2013,02:649-653.

[9]贾佳,宋恩梅,苏环. 社会化问答平台的答案质量评估——以“知乎”、“百度知道”为例[J]. 信息资源管理学报,2013,02:19-28.

[10]余凯,贾磊,陈雨强,徐伟. 深度学习的昨天、今天和明天[J]. 计算机研究与发展,2013,09:1799-1804.

[11]李晓昀. 基于隐性反馈的个性化自适应电子商务推荐系统研究[D].南华大学,2007.

[12]高明,金澈清,钱卫宁,王晓玲,周傲英. 面向微博系统的实时个性化推荐[J]. 计算机学报,2014,04:963-975.

[13]韦勇娇. 认知盈余时代,网络问答社区的知识传播模式探析——以“知乎”为例[J]. 广西职业技术学院学报,2014,01:30-34+40.

[14]何清,李宁,罗文娟,史忠植. 大数据下的机器学习算法综述[J]. 模式识别与人工智能,2014,04:327-336.

[15]Liang Hu,Guohang Song,Zhenzhen Xie,Kuo Zhao. Personalized Recommendation Algorithm Based on Preference Features[J]. Tsinghua Science and Technology,2014,03:293-299.

[16]黄丽. BP神经网络算法改进及应用研究[D].重庆师范大学,2008.

[17]罗频捷,温荷. 基于改进BP神经网络的个性化推荐算法研究[J]. 四川理工学院学报(自然科学版),2016,01:39-43.

[18]肖宇伦,欧阳纯萍,刘志明. 基于SVM和词向量的Web新闻倾向性分析[J]. 现代计算机(专业版),2016,14:52-55.

[19]张蕊. “异军”知乎的突起——浅析知乎的发展现状[J]. 视听,2015,06:147-148.

[20]刘婉婷,章杨. “知乎”的传播模式和未来发展[J]. 新闻世界,2015,08:150-151.

[21]陈景年. 选择性贝叶斯分类算法研究[D].北京交通大学,2008.

致谢

本研究论文是在指导老师李晓昀副教授和欧阳纯萍副教授的悉心指导下完成的。通过分析当前热点技术与社会问题，构建面向知乎的个性化推荐系统，实现将用户与有价值的信息紧密联系起来的目的。在系统建模前期遇到概念混淆等问题，老师给予我们讲解个性化推荐系统，指导我们构建系统模型，中间过程督促我们完成任务并给予指导和评价，最后阶段在论文书写方面给予修改意见。在论文选题、模型构建、书写论文的过程中花费了老师很多宝贵的时间，在此向谨向李老师和欧阳老师致以诚挚的谢意和崇高的敬意。

同时还要感谢团队内每一位队友，大家互相激励，遇到问题时大家积极思考，对论文提出宝贵意见，同时认真完成安排的任务。此篇论文的完成感谢团队的每一位队友，感谢大家的辛劳付出。最后，本团队向百忙之中抽时间对本文进行审阅、评议和参与本人论文答辩的各位老师表示感谢。